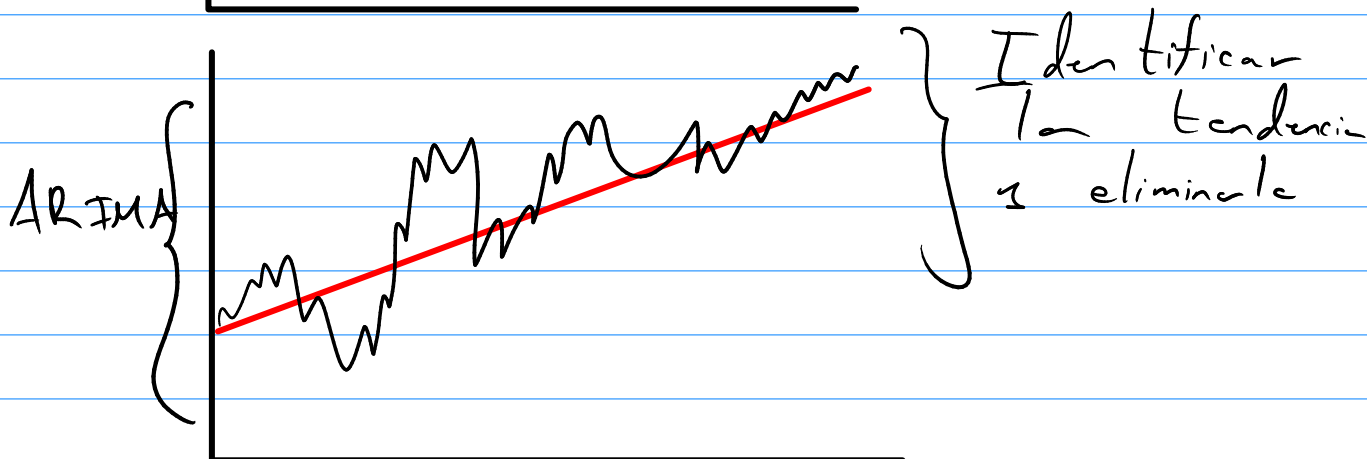



Modelos ARIMA

A } Autocorrelative
 R }
 I } Integrated
 M } Moving Average
 A }



Podemos expresar a los modelos ARIMA de la siguiente forma:

$$\phi_p(B) (1-B)^d X_t = \theta_q(B) Z_t$$

(\rightarrow ARIMA(p, d, q))

$$(1-B)X_t = X_t - X_{t-1}$$

Si: $d=0$, tenemos un proceso ARMA(p, q)

(De hecho, si $y = (1-B)^d X_t \Rightarrow$

y es un proceso ARMA(p, q)

($d=1$)

En finanzas, es común trabajar con series de tiempo transformándolas de la siguiente forma:

$$y_t = \frac{X_t - X_{t-1}}{X_{t-1}}$$

↑ ^{tendencia} Cambio Porcentual
de una serie de tiempo.

↓ ^{normalizar los datos}

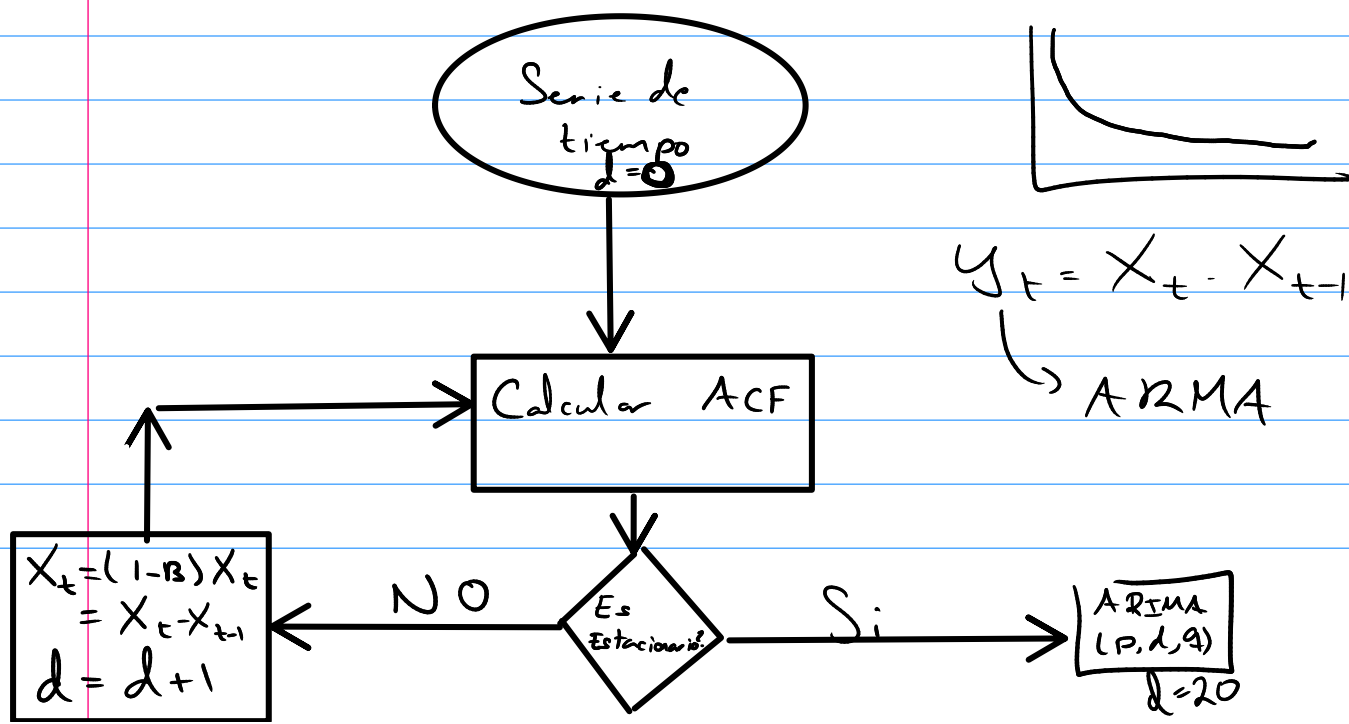
$$(y_t = X_t - X_{t-1})$$

$$X \text{ (USD)} \rightarrow \frac{X_t - X_{t-1} \text{ (USD)}}{X_{t-1} \text{ (USD)}} \%$$

$$(1-B)^2 X_t = (1-B)(1-B)X_t$$

$$= (1-B) \underbrace{(X_t - X_{t-1})}_y = (1-B)y$$

¿Cómo determinar el valor de d ?



Ejemplo:

* Caminata aleatoria:

$$X_t = X_{t-1} + z_t, \quad z_t \sim WN(0, \sigma^2)$$

$$X_t - X_{t-1} = z_t \Leftrightarrow (1-B)X_t = z_t$$

↳ ARIMA(0,1,0)

$$y_t = X_t - X_{t-1} \Rightarrow y_t = z_t$$

Qué pasa si ahora, nuestro modelo es de la siguiente forma:

$$(1-B)X_t = \theta_0 + z_t \quad \text{o'}$$

$$X_t = X_{t-1} + \theta_0 + z_t$$

$$X_t = (X_{t-2} + \theta_0 + z_{t-1}) + \theta_0 + z_t$$

$$X_t = X_{t-2} + 2\theta_0 + z_{t-1} + z_{t-2}$$

$$\vdots$$
$$X_t = X_k + \underbrace{(t-k)\theta_0}_{\text{Drift}} + \sum_{j=k+1}^t z_j$$

$$y_t = (1-B)X_t$$

$$y_t = \theta_0 + z_t \rightarrow y_t - y_{t-1} = (\theta_0 + z_t) - (\theta_0 + z_{t-1})$$

$$(1-B)y_t = (1-B)z_t$$

$$\text{ARIMA}(0,2,1) \rightarrow (1-B)^2 X_t = (1-B)z_t$$

Modelo ARIMA(0,1,1) o IMA(1,1)

$$(1-B)X_t = (1-\theta B)Z_t$$

$$X_t = X_{t-1} + Z_t - \theta Z_{t-1}$$

$$Z_t = \frac{(1-B)}{1-\theta B} X_t$$

$$\sum_{i=1}^{\infty} x^i = \frac{1}{1-x}$$

$$\frac{1-B}{1-\theta B} = (1-B)(1+\theta B+\theta^2 B^2+\dots)$$

$$= (1+\theta B+\theta^2 B^2+\dots) - (B+\theta B^2+\theta^2 B^3+\dots)$$

$$= 1 - (1-\theta)B - (1-\theta)\theta B^2 - (1-\theta)\theta^2 B^3 - \dots$$

$$\text{Definir } \alpha = 1-\theta$$

$$= 1 - \alpha B - \alpha(1-\alpha)B^2 - \alpha(1-\alpha)^2 B^3 - \dots$$


$$\Rightarrow X_t = \alpha \sum_{j=1}^{\infty} (1-\alpha)^{j-1} X_{t-j} + Z_t$$

Supongamos que el mejor estimador para pronosticar el valor futuro de X_t es

$$\hat{X}_t = E[X_t]$$

$$\hat{X}_t = E\left[\alpha \sum_{j=1}^{\infty} (1-\alpha)^{j-1} X_{t-j} + Z_t\right]$$

$$\hat{X}_t = \alpha \sum_{j=1}^{\infty} (1-\alpha)^{j-1} X_{t-j}$$



$$\hat{X}_{t+1} = \alpha \sum_{j=1}^{\infty} (1-\alpha)^{j-1} X_{t+1-j}$$

$$= \alpha (1-\alpha)^{1-1} X_{t+1-1} + \alpha \sum_{j=2}^{\infty} (1-\alpha)^{j-1} X_{t+1-j}$$

$$= \alpha X_t + \alpha (1-\alpha) \sum_{j=2}^{\infty} (1-\alpha)^{j-2} X_{t+1-j}$$

$\underbrace{t+1-j}_{(j-1)-1} \rightarrow \underbrace{t-(j-1)}_{t-i}$

$$= \alpha X_t + (1-\alpha) \alpha \sum_{i=1}^{\infty} (1-\alpha)^{i-1} X_{t-i}$$

$\underbrace{\hspace{10em}}_{\hat{X}_t}$

$$\hat{X}_{t+1} = \alpha X_t + (1-\alpha) \hat{X}_t$$

\searrow El pronóstico de \hat{X}_{t+1} podemos verlo como un promedio ponderado entre la observación X_t y el pronóstico \hat{X}_t

\rightarrow Caso particular de un Filtro de Kalman.